

Proyecto 1. Detección adaptativa de fraude con IEEE-CIS Fraud Detection

Grupo NaN

Contexto del sistema

1. Planteamiento del problema

El crecimiento de los pagos digitales y del comercio electrónico ha incrementado considerablemente la cantidad de transacciones que deben ser procesadas por bancos, emisores de tarjetas y empresas de medios de pago. Dentro de este volumen, una pequeña proporción corresponde a operaciones fraudulentas que pueden generar pérdidas económicas para las instituciones financieras, sus clientes y los comercios asociados.

En el dataset IEEE-CIS Fraud Detection se registran 590,540 transacciones de entrenamiento, de las cuales 20,663 corresponden a fraude, aproximadamente el 3.5 % del total (IEEE Computational Intelligence Society, 2019). El reto consiste en identificar correctamente estas operaciones fraudulentas a partir de variables de transacción, tarjeta, dispositivo e identidad, procurando al mismo tiempo reducir los falsos positivos que podrían bloquear compras legítimas.

2. Justificación e importancia

El fraude financiero representa un problema económico de gran magnitud. Nasdaq estimó que durante 2023 las estafas y esquemas de fraude bancario generaron aproximadamente US\$485.6 mil millones en pérdidas proyectadas a nivel mundial (Nasdaq, 2024). Esto demuestra que incluso pequeñas mejoras en la capacidad de detección pueden tener un impacto económico importante cuando se aplican sobre millones de transacciones.

Además, el costo para las instituciones financieras puede superar ampliamente el monto directamente sustraído. LexisNexis Risk Solutions estimó que cada US\$1 perdido directamente por fraude representa aproximadamente US\$4.41 de costo total para una institución financiera, considerando gastos adicionales asociados a su gestión (LexisNexis Risk Solutions, 2024). Por ello, el uso de modelos de aprendizaje automático para detectar patrones de fraude puede contribuir a reducir pérdidas y mejorar la seguridad de las transacciones.

1. Definición de objetivos

Objetivo general

Desarrollar un sistema inteligente adaptativo para la detección de fraude en transacciones electrónicas que permita estimar el riesgo de fraude, apoyar la toma de decisiones y mantener un desempeño adecuado ante cambios en los patrones transaccionales a lo largo del tiempo.

Objetivos específicos

Objetivo 1. Detectar transacciones fraudulentas

Identificar transacciones fraudulentas a partir de la información disponible al momento de cada transacción, comparando modelos de clasificación mediante una evaluación temporal y seleccionando aquel que obtenga el mejor desempeño en **PR-AUC**, complementado con **Recall, Precision y F1-score** sobre datos futuros.

Objetivo 2. Optimizar la decisión basada en riesgo

Definir una política de decisión que transforme el riesgo estimado de fraude en acciones de aprobación, revisión o escalamiento, seleccionando sus umbrales sobre datos de validación para **minimizar el costo esperado de decisión**, sujeto a una capacidad máxima de revisión manual.

Objetivo 3. Detectar degradación temporal

Identificar periodos en los que cambios en la distribución de los datos estén acompañados por una degradación del desempeño predictivo, mediante monitoreo por ventanas temporales y cuantificando la variación de **PR-AUC, Recall y F1-score** junto con una medida de *distribution shift*.

Objetivo 4. Adaptar el sistema ante cambios temporales

Evaluar una estrategia adaptativa de reentrenamiento con ventanas temporales recientes frente a un modelo estático, buscando **reducir la degradación de PR-AUC, Recall y F1-score** en ventanas futuras después de detectar cambios relevantes.

Trazabilidad de los objetivos

Objetivo	Tarea	Método	Métricas de éxito	Criterio de éxito
O1. Detectar fraude	Clasificación binaria de transacciones	Comparación de modelos tradicionales y avanzados con	PR-AUC , Recall, Precision y F1-score	Superar el baseline en validación y mantener el

Objetivo	Tarea	Método	Métricas de éxito	Criterio de éxito
		división temporal train-validation-test		mejor desempeño posible sobre ventanas futuras
02. Optimizar decisiones	Convertir el riesgo estimado en aprobar, revisar o escalar	Selección de umbrales sobre validación mediante una función de costo	Costo esperado , fraude no detectado y % de revisión	Reducir el costo esperado respecto a la política baseline sin superar la capacidad de revisión definida
03. Detectar degradación	Monitorear cambios en datos y desempeño	Evaluación por ventanas temporales + medida de <i>distribution shift</i>	ΔPR-AUC, ΔRecall, ΔF1 y medida de shift	Identificar periodos de cambio y cuantificar si están asociados con degradación predictiva
04. Adaptarse al cambio	Actualizar el modelo utilizando información reciente	Reentrenamiento o mediante <i>sliding window</i> y comparación Static vs. Adaptive	PR-AUC, Recall y F1-score por ventana	Obtener menor degradación temporal con el sistema adaptativo que con el modelo estático

2. Restricciones

El sistema deberá operar considerando las siguientes limitaciones:

Tipo	Restricción	Implicancia para el sistema
Datos	Desbalance entre transacciones legítimas y fraudulentas	La exactitud global puede resultar poco representativa, por lo que se priorizarán métricas orientadas a la clase fraudulenta.
Datos	Naturaleza temporal de las transacciones	El entrenamiento y la evaluación deberán respetar estrictamente el orden temporal para evitar fuga de información futura.

Tipo	Restricción	Implicancia para el sistema
Datos	Variables anonimizadas	La anonimización limita la interpretación causal de determinados cambios observados en la distribución.
Datos	Valores faltantes e información de identidad incompleta	El sistema deberá ser capaz de procesar transacciones con distintos niveles de información disponible.
Operación	Cambios en los patrones de fraude	El desempeño de un modelo entrenado una única vez puede degradarse, por lo que será necesario monitorearlo a lo largo del tiempo.
Operación	Disponibilidad retrasada de etiquetas	En un escenario real, la confirmación de fraude puede no estar disponible inmediatamente, limitando el monitoreo instantáneo del desempeño supervisado.
Operación	Capacidad limitada de revisión humana	Solo una fracción de las transacciones podrá ser escalada para revisión manual.
Recursos	Costo de entrenamiento y actualización	El sistema no podrá depender de reentrenamientos continuos innecesarios; las actualizaciones deberán realizarse de manera controlada.
Decisión	Costo asimétrico de errores	Un fraude no detectado y una transacción legítima marcada incorrectamente producen consecuencias diferentes y deberán ponderarse de forma distinta.
Decisión	Autonomía limitada	El modelo proporcionará una estimación de riesgo y una recomendación; los casos inciertos o de alto impacto podrán requerir intervención humana.

3. Métricas de éxito

3.1. Métricas técnicas

El desempeño predictivo del sistema será evaluado principalmente mediante métricas adecuadas para problemas de clasificación desbalanceada.

- **PR-AUC:** métrica principal para comparar la capacidad de los modelos de distinguir transacciones fraudulentas.
- **Recall:** proporción de transacciones fraudulentas correctamente detectadas.
- **F1-score:** medida del equilibrio entre Precision y Recall.
- **Latencia de inferencia:** tiempo requerido para obtener una predicción para una nueva transacción.
- **PR-AUC, Recall y F1-score por ventana temporal:** permitirán cuantificar la degradación del modelo conforme evolucionan los datos.

La **accuracy no será utilizada como métrica principal**, debido al desbalance entre transacciones legítimas y fraudulentas.

3.2. Métricas de decisión

La utilidad del sistema se evaluará considerando las consecuencias de las decisiones producidas a partir de sus predicciones.

Se utilizará un **costo esperado** que considere tres componentes:

$$C = C_{FN} \cdot FN + C_{FP} \cdot FP + C_{review} \cdot N_{review}$$

donde:

- C_{FN} representa el costo asociado a una transacción fraudulenta no detectada;
- C_{FP} representa el costo o fricción ocasionada por identificar incorrectamente una transacción legítima como sospechosa;
- C_{review} representa el costo de realizar una revisión manual;
- N_{review} corresponde al número de transacciones enviadas a revisión.

Los valores utilizados para estos costos deberán definirse y justificarse antes de seleccionar la política de decisión.

Adicionalmente, se medirán:

- **Tasa de fraude no detectado**, como indicador del riesgo residual.
- **Porcentaje de transacciones enviadas a revisión**, como indicador de carga operacional.
- **Tiempo de respuesta**, desde la recepción de la transacción hasta la generación de una recomendación.

3.3. Métricas sociales y de riesgo

La evaluación considerará el impacto que las decisiones del sistema pueden generar sobre transacciones legítimas y su capacidad para operar sobre la población de transacciones recibidas.


- **False Positive Rate (FPR):** permitirá medir la proporción de transacciones legítimas incorrectamente identificadas como fraudulentas.

- **Tasa de escalamiento a revisión:** permitirá cuantificar la fricción adicional generada por el sistema.
- **Cobertura automática:** porcentaje de transacciones sobre las cuales el sistema puede producir una recomendación sin requerir revisión adicional.

La evaluación de **equidad entre grupos** se realizará únicamente si el conjunto de datos contiene segmentos interpretables y apropiados para realizar comparaciones válidas. En ese caso, podrán compararse métricas como FPR o Recall entre segmentos.

Debido a la anonimización presente en IEEE-CIS, no se inferirán características demográficas a partir de variables cuyo significado no sea conocido. Si los datos disponibles no permiten evaluar rigurosamente la equidad demográfica, esta condición será reportada explícitamente como una limitación del sistema.

3.4 Arquitectura del sistema



Arquitectura del sistema adaptativo de detección de fraude. Las variables transaccionales y de identidad son integradas y procesadas antes de ingresar al modelo predictivo, que estima la probabilidad de fraude. Esta estimación es transformada mediante umbrales de riesgo en una recomendación de aprobación, revisión o escalamiento. Las predicciones, decisiones y etiquetas posteriormente disponibles alimentan un módulo de monitoreo temporal que evalúa cambios en la distribución y degradación del desempeño. Ante evidencia suficiente de degradación, se entrena un modelo candidato utilizando información reciente, que reemplaza al modelo vigente únicamente si mejora su desempeño bajo el protocolo de validación temporal.

Referencias

IEEE Computational Intelligence Society. (2019). *IEEE-CIS Fraud Detection* [Conjunto de datos]. Kaggle. [IEEE-CIS Fraud Detection](#)

LexisNexis Risk Solutions. (2024, 24 de abril). *Every dollar lost to a fraudster costs North America's financial institutions \$4.41 according to LexisNexis True Cost of Fraud Study from LexisNexis Risk Solutions*. [LexisNexis Risk Solutions](#) [LexisNexis Risk](#)

Nasdaq. (2024, 16 de enero). *Nasdaq releases first Global Financial Crime Report, measuring the scale and human impact of financial crime*. [Nasdaq](#) [Nasdaq, Inc.](#)

UK Finance. (2026). *Annual Fraud Report 2026*. UK Finance. [Annual Fraud Report 2026](#)

Data drift estrategia mas sencilla (sliding window)

hay 4 metodos

temporal por meses

no cumple politica de calidad (thresholds)

si no cumple, reentrenar

analisis de escenarios