

Sistema temporal de decisión antifraude

Validación, costo y adaptación en IEEE-CIS

Proyecto 1 · 2026-1 · Grupo NaN

Resumen. Integramos transacciones e identidad de IEEE-CIS y construimos una política de aprobar, revisar o escalar. La selección de modelos e hiperparámetros usa exclusivamente pasado y validación; la política minimiza el peor arrepentimiento porcentual bajo cuatro escenarios de costo. En validación ganó XGBoost con ventana periódica de 30 días. En la evaluación histórica final obtuvo PR-AUC 0.548 y F1 0.485 al umbral de escalación. Bajo el escenario 80/95, el costo simulado fue 12.312 por transacción, frente a 30.484 al aprobar todo. Las cifras monetarias son una simulación bajo eficacias supuestas, no ahorros observados.

1 Problema y objetivos

Una entidad que autoriza pagos digitales debe decidir con poca demora qué transacciones deja pasar y cuáles envía a sus analistas. IEEE-CIS contiene 590 540 transacciones etiquetadas: en los periodos visibles, el fraude pasa de 2.53% a cerca de 4% y la identidad ausente supera 81%. Una clasificación binaria aislada no resuelve la decisión: revisar todos los casos sospechosos excede la capacidad humana, mientras aprobar sin control permite pérdidas. Además, la confirmación de fraude llega después de la transacción, de modo que la calidad del modelo sólo puede medirse con retraso.

El sistema propuesto estima riesgo al momento de cada transacción y recomienda *aprobar*, *revisar* o *escalar*. El equipo antifraude es el usuario de las dos colas y decide los casos revisados. Un falso negativo deja pasar fraude; un falso positivo puede retrasar una compra legítima y consumir trabajo humano. La pregunta de decisión es: *¿qué combinación de modelo, umbrales y capacidad reduce la pérdida simulada de forma estable cuando cambian los datos?* No se pretende concluir culpabilidad ni ejecutar sanciones irreversibles automáticamente.

Objetivo general. Diseñar y evaluar, con transacciones IEEE-CIS ordenadas en el tiempo, un sistema de apoyo a decisiones antifraude que traduzca riesgo en acciones operativas sujetas a capacidad humana y que conserve una política explícita de control de calidad y adaptación.

Objetivos específicos.

1. Caracterizar por periodos la prevalencia, los faltantes, las anomalías y los cambios de distribución; construir variables disponibles antes de cada decisión.
2. Comparar modelos tradicionales y avanzados bajo el mismo protocolo temporal y seleccionar sus hiperparámetros con entrenamiento y validación históricos.
3. Convertir las predicciones en aprobación, revisión o escalación mediante una política de costo y capacidad, evaluada en varios escenarios de eficacia.
4. Monitorear desempeño con etiquetas maduras y evaluar una regla de reentrenamiento, validación y promoción que proteja al sistema frente a degradación sostenida.

Estos objetivos siguen el recorrido *datos* → *predicción* → *decisión* → *acción* → *monitoreo*. Las secciones siguientes muestran la evidencia correspondiente; ningún objetivo fija una puntuación que el experimento deba alcanzar de antemano.

2 Restricciones y métricas de éxito

La tabla consolida siete restricciones con su consecuencia concreta. Se distinguen límites del experimento y condiciones que todavía habría que verificar en un despliegue.

Ámbito	Restricción	Regla o implicancia
Temporalidad	Las etiquetas llegan tarde y la población cambia.	Corte 70/15/15; cada ajuste espera siete días de etiquetas; métricas por periodo.
Disponibilidad	Hay identidad faltante y variables anonimizadas sin contrato de disponibilidad en producción.	Conservar faltantes; ajustar transformaciones en pasado; verificar cada campo antes de operar.
Desbalance	El fraude es minoritario y la exactitud global puede ocultar errores.	Priorizar PR-AUC y observar recall, F1 y costo por periodo.
Revisión	El equipo humano sólo puede iniciar una fracción de revisiones.	Cupo supuesto del 5% de la mediana diaria elegible: 159 casos; sensibilidad 3/10%.
Escalación	La segunda cola no tiene capacidad ni eficacia humana medidas.	Contar directas y derivadas por separado; dimensionar la cola en piloto.
Recursos	Entrenar continuamente consume cómputo y puede desestabilizar la política.	Ventanas acotadas; dos brechas maduras antes de activar candidato; gate antes de promover.
Autonomía y datos sociales	La recomendación no prueba fraude; no hay atributos demográficos interpretables.	Analistas deciden casos revisados; informar cobertura UID sin afirmar equidad demográfica.

Cuadro 1: Restricciones de datos, operación, recursos y autonomía con efecto en el diseño.

Tipo	Medida principal	Baseline o regla de interpretación
Técnica	PR-AUC ↑, recall ↑, F1 ↑ y latencia p95 ↓. Brier ↓ apoya la calibración.	PR-AUC aleatoria $\approx$ prevalencia: 3.43% en validación IEEE-CIS. Comparar además con regresión y árbol en los mismos folds. Latencia aún no medida para este pipeline.
Decisión	Costo por transacción ↓, pérdida evitada ↑ y carga diaria de ambas colas ↓ bajo calidad suficiente.	Aprobar todo: 34.078 por transacción en la subventana de selección; comparar cuatro escenarios y respetar el cupo inicial.
Social y operativa	Cobertura y PR-AUC por UID conocido/no visto; tasa de transacciones legítimas enviadas a revisión o escalación.	En el holdout histórico, 89.35% recibe aprobación automática y 8.47% de las legítimas entra en una cola; sin inferencia de equidad demográfica.

Cuadro 2: Métricas conectadas con el error y referencias verificables.

La prevalencia de referencia procede de `validation_predictions.csv.gz`; el costo base de selección se reconcilia con `validation_scenarios.csv`. La cobertura y fricción se calculan desde `holdout_decisions.csv.gz`. Los costos unitarios externos se documentan en la sección de escenarios. La latencia p95 es un criterio de aceptación de despliegue: no le atribuimos un valor medido por los notebooks offline.

3 Datos y protocolo temporal

IEEE-CIS aporta 590 540 transacciones etiquetadas. Unimos las tablas de transacciones e identidad por identificador único y conservamos las identidades faltantes. El EDA usa periodos relativos de 30 días y oculta las etiquetas del holdout. La prevalencia visible pasó de 2.53% en el primer periodo a alrededor de 4.0% en los periodos segundo a cuarto; la ausencia de identidad pasó de 56.8% a más de 81%. Estas variaciones justifican un análisis por periodo y una partición cronológica.




Figura 1: Prevalencia, identidad, cambio de monto y faltantes en periodos relativos de 30 días anteriores al holdout. El sexto periodo es parcial.

El perfil de faltantes cubre las 431 variables originales. Como anomalía de calidad, M7--M9 cambian 50.4 puntos porcentuales entre periodos, mientras varias columnas V cambian 46.9 puntos. El KS de monto frente al primer periodo llega a 0.056: es señal de cambio en $P(X)$, no prueba de concept drift. Las asociaciones Pearson/V de Cramér y la importancia de un LightGBM diagnóstico se calcularon con historial y una muestra de validación; son exploratorias y no determinaron la política final.

Ordenamos por TransactionDT y fijamos 70/15/15 para entrenamiento, validación y holdout. Dos folds internos, dentro del entrenamiento inicial, evalúan los tramos 50–65% y 75–90% de su duración. Cada ajuste termina antes de $t - 7$ días, porque suponemos una demora de siete días en recibir etiquetas. El primer bloque de validación se reserva para calibración; sus últimos siete días no informan la elección al comienzo del holdout.

Excluimos TransactionID, TransactionDT, la etiqueta y el UID de los predictores. Cinco atributos de memoria por UID se calculan sólo con eventos anteriores. Selección de columnas V, codificaciones categóricas, frecuencias, estadísticos de monto e imputación se ajustan en cada ventana de entrenamiento. Las variables anonimizadas carecen de un contrato real de disponibilidad al momento de autorizar una transacción: esta es una incertidumbre de despliegue.

4 Modelos y selección

Comparamos dos modelos tradicionales, regresión logística y árbol de decisión, con LightGBM y XGBoost. Los grids compactos se fijaron antes de evaluar el holdout. Elegimos hiperparámetros por PR-AUC media de los dos folds internos; después, por su peor fold y menor complejidad. El registro de 28 ajustes internos confirma `train_last_dt < available_before` y que ambos folds terminan dentro del entrenamiento inicial.

Modelo	PR-AUC interna ↑	Hiperparámetros elegidos
LightGBM	0.560	63 hojas; 100 observaciones por hoja
XGBoost	0.536	profundidad 6; peso mínimo 30
Árbol de decisión	0.387	profundidad 10; hoja mínima 100
Regresión logística	0.374	$C = 0.1$

Cuadro 3: Orden descendente de PR-AUC interna; turquesa marca el mejor ranking, no la política de menor costo. Selección exclusivamente dentro del entrenamiento inicial.

Los cuatro modelos estáticos comparten el mismo protocolo de validación. Para LightGBM y XGBoost también reproducimos ventanas periódicas de 30, 60 y 90 días, más una ventana de 60 días disparada por calidad. La versión disparada sin gate es comparador técnico; no participa en la selección económica. LightGBM periódico de 60 días obtuvo la mayor PR-AUC de validación completa (0.586), pero la política XGBoost de 30 días obtuvo el menor costo en los cuatro escenarios de la subventana destinada a decidir.




Figura 2: Izquierda: PR-AUC semanal de la configuración elegida en cada fold interno; la línea separa folds, no semanas calendario contiguas. Derecha: ventanas periódicas avanzadas en validación.

La media de cada fold oculta variación semanal. Los ensambles mantienen ventaja frente a los baselines tradicionales, pero su rendimiento fluctúa; no basta con presentar un único resultado agregado. LightGBM 60 días ordenó mejor la validación completa, mientras la selección económica posterior favoreció XGBoost 30 días. Una caída puntual puede incluir ruido, cambio de prevalencia o covariables; por eso la política de adaptación exige dos mediciones maduras consecutivas bajo la cota. Ni KS ni faltantes prueban por sí solos un cambio en $P(Y | X)$.

5 Función de costo y elección en validación

Para cada transacción, cobramos 0.65 por revisión inicial, 4 por escalación directa, 4 por fraude identificado en revisión y derivado a escalación, y $5.75 \times \text{TransactionAmt}$ por fraude no detenido. Si la revisión tiene eficacia q_R y la escalación q_E , el fraude revisado deja fracción residual $1 - q_R q_E$; el escalado directamente deja $1 - q_E$. El costo evitado es el costo de aprobar todo menos el costo de la política: no tratamos el monto de la transacción como ingreso.

El precio de 0.65 sale de 0.75 minutos a 52 USD/hora en el [TEI de Forrester encargado por Mastercard](#). Sus 4 USD corresponden a seguimiento de un subconjunto de falsas alertas; aplicarlos aquí a una escalación por fraude confirmado es **nuestro supuesto de flujo**. El multiplicador 5.75 proviene del [estudio 2025 de LexisNexis para servicios financieros de EE. UU.](#) La divisa de TransactionAmt es desconocida y ese multiplicador total puede incluir trabajo operativo ya cobrado: los importes son comparaciones de escenarios, no ahorros observados.

Probamos eficacias revisión/escalación 100/100, 90/98, 80/95 y 60/90. Para cada modelo y par de umbrales, calculamos costo en la misma subventana de validación. Elegimos menor *peor arrepentimiento porcentual* frente al mínimo de cada escenario; desempates: arrepentimiento medio, PR-AUC y complejidad. Ganó XGBoost periódico de 30 días con umbrales 0.3872/0.6521 y arrepentimiento máximo 0% dentro del grid. La selección, su hash y los parámetros quedaron congelados antes de leer etiquetas del holdout.

Eficacia revisión/escalación	Costo/txn validación ↓	Costo/txn holdout ↓	Pérdida evitada ↑
100/100	8.106	10.227	1.794 millones
90/98	9.189	11.184	1.710 millones
80/95 (central)	10.499	12.312	1.610 millones
60/90	12.776	14.286	1.435 millones

Cuadro 4: Escenarios ordenados de menor a mayor costo. Turquesa: escenario central del análisis; coral: supuesto más adverso. Una política elegida en validación, sin retocar umbrales.




Figura 3: Costo retrospectivo por escenario y sensibilidad del cupo de revisión en validación (80/95). La línea discontinua representa aprobar todo.

Al pasar el cupo de 3% a 5% y 10% en validación, el costo por transacción del escenario 80/95 fue 12.127, 10.499 y 9.326, respectivamente. Es sensibilidad de capacidad, no promesa de dotación.

6 Evaluación final retrospectiva

El holdout contiene 88 581 transacciones y 3 083 fraudes. XGBoost con ventana de 30 días se reajusta semanalmente sólo con etiquetas maduras. La PR-AUC global fue **0.548**; al umbral congelado de escalación, recall **0.597** y F1 **0.485**. El Brier bruto fue 0.06863; una isotónica ajustada en la primera semana de validación y aplicada sin refit al holdout dio 0.02195. La calibración sirve para comunicar probabilidad y no modificó el ranking ni los umbrales.

Con el escenario 80/95, aprobar todo costaría 2.700 millones ilustrativos; la política costó 1.091 millones y evitó 1.610 millones (59.6%). Hubo 4 929 revisiones iniciales, 4 505 escalaciones directas y 280 derivaciones esperadas desde revisión. En 31 días de holdout, el cupo de 159 revisiones se utilizó completo cada día. La demanda de escalación promedió 154.4 por día y llegó a 376.8; hace falta dimensionar esa segunda cola antes de operar. Se aprobaron 893 fraudes y se estima que 2 014 se detendrían bajo 80/95. Son valores esperados bajo eficacias supuestas.

Periodo relativo	PR-AUC ↑	Costo/txn ↓	F1 ↑	Filas	Fraudes
Mes 6	0.542	12.077	0.480	83 088	2 842
Mes 7 (parcial)	0.612	15.870	0.543	5 493	241

Cuadro 5: Orden cronológico para mostrar evolución, con métricas decisivas primero. Escenario de costo 80/95; el último periodo es parcial.

El 55.4% de las filas del holdout tiene UID no visto antes (49 069; PR-AUC 0.570); el 44.6% restante tiene UID conocido (39 512; PR-AUC 0.487). Este contraste identifica un segmento a monitorear, sin inferir causalidad ni trato desigual a personas.




Figura 4: Carga diaria de escalación esperada bajo 80/95. La línea de 159 es el cupo de revisiones iniciales, no un límite validado para escalaciones.

La fila de revisión se usó completamente los 31 días, mientras la segunda cola alcanzó 376.8 escalaciones esperadas en el máximo diario. La distinción evita ocultar un posible cuello de botella: la simulación económica supone que todas las escalaciones se procesan con la eficacia indicada por el escenario, pero no mide tiempo de respuesta ni dotación suficiente.

7 Control de calidad y regla de adaptación

La cota de PR-AUC semanal, 0.4897, es el percentil 10 de las semanas de validación interna del modelo elegido. Cada semana sólo se consultan bloques cuyas etiquetas tienen al menos siete días. Dos incumplimientos maduros consecutivos disparan un candidato entrenado en los últimos 60 días elegibles; una semana histórica calibra su política y otra, posterior y separada, decide la promoción. Se conserva el vigente si no mejora la PR-AUC y el peor costo de escenario. En esta corrida hubo una semana madura bajo la cota, seguida de recuperación; no se atribuye una mejora a un reentrenamiento que no ocurrió. KS y cambios de faltantes diagnostican drift, pero no disparan por sí solos.





Figura 5: Separación entre PR-AUC observada y la última disponible con etiquetas maduras al decidir. La trayectoria observada no puede usarse anticipadamente.

Periodo	Última PR-AUC ↑	Cota	Acción	PR-AUC posterior ↑
Mes 6	0.497	0.490	Mantener	0.512
Mes 7 (parcial)	0.497	0.490	Mantener	0.571

Cuadro 6: Bitácora mensual de métrica, umbral, decisión y resultado del controlador sombra.

La regla tiene cuatro resultados posibles. Una semana madura sobre la cota mantiene el vigente. La primera semana bajo cota registra una alerta; la segunda consecutiva entrena con los últimos 60 días elegibles. Si el candidato no supera al vigente en PR-AUC y peor costo sobre el gate posterior, el sistema mantiene la versión previa. En esta corrida se observó la primera alerta, seguida de recuperación; por ello no hubo reentrenamiento ni promoción. La métrica posterior se muestra para comprobar la consecuencia de *mantener*, sin utilizarla para decidir antes de que llegaran sus etiquetas.

8 Arquitectura, autonomía y límites de despliegue



Un despliegue requeriría ingestión con sello temporal, repositorio de variables con historial, servicio de inferencia, cola con estado para el cupo diario, registro de acciones, llegada tardía de etiquetas y un proceso de promoción auditado. El código reproduce la simulación y el gate; no demuestra latencia, capacidad real ni eficacia humana. La evaluación usa datos históricos y no sustituye una prueba prospectiva con nuevas transacciones. La moneda desconocida, el solapamiento potencial de costos, la disponibilidad incierta de variables anonimizadas y la ausencia de atributos demográficos limitan cualquier conclusión económica o social.

IEEE-CIS integra dos tablas estructuradas; no ofrece imágenes ni texto libre verificables. En un entorno real podrían añadirse nuevas modalidades sólo después de establecer permisos, calidad y disponibilidad al momento de autorizar. La propuesta automatiza score y asignación inicial, pero mantiene intervención humana en la revisión y exige un gate antes de promover otro modelo. La cola de escalación alcanzó una demanda esperada de 376.8 casos en un día: esa capacidad debe dimensionarse antes del despliegue.

Mapa de la rúbrica. Problema y objetivos: sección 1. Restricciones y tres tipos de métricas: sección 2. Evolución y preparación temporal: sección 3. Comparación y degradación: sección 4. Costos y decisiones: sección 5. Evaluación y adaptación: secciones 6–7. Arquitectura y autonomía: sección 8. Los notebooks y CSV de `08_entrega_final_codigo/` permiten auditar cada cifra.

Reproducibilidad. Los cuatro notebooks, outputs y verificaciones se encuentran en `08_entrega_final_codigo/`. El verificador confirmó cortes de entrenamiento, demora de etiquetas, selección congelada, capacidad diaria, conciliación de costos y gate de adaptación sobre los outputs IEEE-CIS descargados de kernels privados de Kaggle.