

Sistema adaptativo de detección de fraude

Decisiones bajo datos no estacionarios en IEEE-CIS

Departamento de Ciencia de la Computación · Proyecto 1 · 2026-1

Equipo: _____ Fecha: _____

Resumen. Se diseña y evalúa un sistema inteligente adaptativo para detección de fraude financiero con datos temporales. El sistema integra transacciones e identidad, estima un score con un modelo LightGBM, traduce el score en acciones operativas y propone monitoreo de drift, calibración y reentrenamiento con ventanas deslizantes. Los resultados provienen de artefactos V01–V07 publicados como kernels de Kaggle y descargados al repositorio. La recomendación final es usar V01 como modelo base, V05 como política inicial y V06 como soporte de robustez/calibración.

1 Problema, objetivos y restricciones


El conjunto IEEE-CIS Fraud Detection contiene transacciones electrónicas y atributos de identidad unidos por `TransactionID`. El caso de uso es clasificar transacciones futuras como riesgo bajo, riesgo intermedio o riesgo alto, para decidir si se aprueban, se envían a revisión humana o se escalan. El problema es no estacionario: la tasa de fraude y la distribución de variables cambian en el tiempo. En la literatura, este fenómeno se asocia a *concept drift*, es decir, cambios temporales en la relación entre entradas y salida (Gama et al., 2014).

Objetivo	Métrica	Restricción o riesgo
Detectar fraude	PR-AUC, ROC-AUC, recall por ventana	Clase positiva minoritaria; no usar accuracy como criterio central.
Decidir con capacidad limitada	Costo normalizado, fraude capturado, revisión, escalamiento	Capacidad objetivo de revisión cercana a 5%.
Controlar incertidumbre	Brier, calibración, estabilidad del score	No comunicar score bruto como probabilidad sin calibración.
Monitorear drift	KS, PSI, missingness, métricas por ventana	No asumir que el entrenamiento representa indefinidamente al futuro.
Reducir fricción social	Legítimas escaladas, UID conocido/desconocido	Evitar automatizar casos ambiguos sin revisión humana.

La métrica principal de modelado es PR-AUC porque el fraude representa sólo 3.50% del entrenamiento; en datos desbalanceados, las curvas Precision-Recall son más informativas que ROC o accuracy para evaluar la clase minoritaria (Saito & Rehmsmeier, 2015). ROC-AUC se reporta como complemento.

2 Análisis y preparación temporal

El EDA propio reporta 590 540 transacciones etiquetadas, 506 691 registros de competencia sin etiqueta, 3.499% de fraude en entrenamiento, 74 variables con más de 80% de faltantes y tasa semanal de fraude entre 1.85% y 5.06%. Además, la validación adversarial train/test alcanzó ROC-AUC 1.000, señal de cambio observable entre periodos. Esto exige validación cronológica y evita tratar el problema como i.i.d.



Las transacciones se ordenan por `TransactionDT`. Los primeros 70% se usan para entrenamiento, el 15% siguiente para validación y el 15% final como holdout futuro. `TransactionDT`, `DT_day_index` y `DT_week_index` no se usan como predictores porque codifican posición temporal absoluta; se reservan para partición y monitoreo. Las agregaciones por UID se consideran válidas sólo si usan información disponible antes de la transacción evaluada.

3 Modelado y evaluación temporal

La línea base V01 usa LightGBM con 185 atributos y *early stopping*. La selección se justifica por la naturaleza tabular del dataset: variables numéricas, categóricas codificadas, faltantes e interacciones no lineales. Posteriormente se ejecutaron controles: V01b con todas las features, V02 con features UID históricas, V03 de auditoría de variables, V04 con LightGBM, XGBoost y CatBoost sobre sets auditados, y V07 con baseline tradicional y MLP. EDA y V01–V07 quedan trazables como kernels públicos de Kaggle.

Versión	Objetivo	Resultado principal	Decisión
V01	Baseline temporal LightGBM	Holdout PR-AUC 0.5436	Modelo base.
V01b	Usar todas las features	Holdout PR-AUC 0.5303	No reemplaza V01.
V02	Features UID históricas	UID conocido mejora; UID desconocido empeora	No adoptar como modelo único.
V03	Auditoría de importancia y drift	44 keep, 9 monitor	Usar para monitoreo.
V04	Comparar LightGBM/XGBoost/Cat-Boost	Ninguno supera V01	Mantener V01.

Evaluación V01	Prevalencia	PR-AUC	ROC-AUC
Validación global	3.43%	0.5954	0.9257
Holdout global	3.48%	0.5436	0.9051
Holdout UID conocido	1.93%	0.5159	0.9020
Holdout UID desconocido	4.73%	0.5632	0.8933

La caída de PR-AUC entre validación y holdout es consistente con degradación temporal. V02 demuestra que el historial UID sí contiene señal: en holdout UID conocido, `uid_freq_amt` sube de 0.5946 a 0.6831; sin embargo, UID desconocido cae de 0.5458 a 0.5315. Por ello no se adopta como modelo único. V04 confirma que podar agresivamente features reduce señal: el mejor candidato auditado queda en 0.5131 de PR-AUC holdout, por debajo de V01. V07 agrega un MLP ponderado y una regresión logística SGD: en holdout obtienen PR-AUC 0.2218 y 0.1638, por debajo de LightGBM de referencia con 0.5313.

Nota sobre la rúbrica. V07 agrega un baseline tradicional lineal y un MLP. Si el docente exige literalmente dos modelos tradicionales distintos, aún conviene agregar un bosque aleatorio simple; esto no cambiaría la recomendación actual, pero cerraría ese ítem formal.

4 Arquitectura, incertidumbre y decisión




Figura 1: Arquitectura funcional propuesta para predicción, decisión y adaptación.

V06 muestra que el score bruto no debe interpretarse directamente como probabilidad: en holdout su promedio fue 14.30% mientras la tasa real fue 3.48%. La calibración isotónica redujo Brier de 0.0479 a 0.0219 y alineó el promedio calibrado a 3.55%. Esto es coherente con la literatura: modelos fuertes pueden rankear bien pero producir probabilidades sesgadas, por lo que Platt scaling o isotonic regression son herramientas apropiadas para calibración (Niculescu-Mizil & Caruana, 2005; Zadrozny & Elkan, 2002).

Acción	Regla V05	Control de incertidumbre
Aprobar	$s < 0.459783$	Registrar decisión y permitir auditoría posterior.
Revisar	$0.459783 \leq s < 0.779122$	Analista valida el caso y aporta etiqueta diferida.
Escalar	$s \geq 0.779122$	Bloqueo temporal o verificación adicional con revisión humana.

En V05, los costos normalizados son 100 por fraude aprobado, 10 por legítima escalada y 2 por revisión manual. La política se selecciona en validación y se aplica a holdout sin recalibrar. La corrida pública de Kaggle confirma los mismos umbrales y métricas que el script local.

Política en holdout	Costo/txn	Fraude detectado	Revisión	Escalamiento
Aprobar todo	3.4804	0.00%	0.00%	0.00%
Revisar top 5%	1.5247	59.20%	5.23%	0.00%
Escalar top 1%	2.5959	25.75%	0.00%	1.01%
V05	1.3680	66.17%	5.10%	2.48%

V05 supera a reglas simples, aunque la revisión en holdout (5.10%) excede levemente el objetivo de 5%. En producción, si el cupo fuera estricto, se recomienda usar umbrales por percentil temporal o una cola con capacidad fija. V06, también ejecutado como kernel público, confirma que la política responde de forma coherente ante escenarios alternativos de costo y capacidad.

5 Despliegue y ciclo de vida

La propuesta de despliegue sigue el taller de GCP: API, contenedor, Artifact Registry, Cloud Build y Cloud Run. La API `POST /predict` recibe una transacción, genera features, calcula score, aplica la política y retorna score, probabilidad calibrada opcional, decisión y versiones. Cloud Run es adecuado porque sirve contenedores HTTP, escala según demanda y se integra con Cloud Logging/Monitoring. Según la documentación oficial, Cloud Build puede construir la imagen, almacenarla en Artifact Registry y desplegarla en Cloud Run de forma automatizada.

Elemento	Cadencia propuesta	Regla de cambio
Operación y cupo	Diario	Vigilar revisión, escalamiento, legítimas afectadas y latencia.
Desempeño con etiquetas	Semanal	PR-AUC, recall, Brier y costo por bloque y segmento.
Umbrales y calibración	Semanal / mensual	Ajustar sólo con datos anteriores a la ventana evaluada.
Modelo	Mensual o alerta sostenida	Comparar candidato frente al vigente en bloque futuro intocado.

6 Drift y adaptación

La detección de drift combina señales inmediatas y señales con etiquetas tardías. Para numéricas se propone KS; para variables agrupadas o categóricas, PSI y cambios de missingness; para scores, percentiles y tasa sobre umbrales; para desempeño, PR-AUC, Brier, recall y costo por ventana. Las estrategias de olvido por ventanas deslizantes se apoyan en la idea de que datos antiguos pueden volverse menos relevantes cuando cambia el proceso generador (Bifet & Gavalda, 2007).

Escenario por simular	Entrenamiento antes del bloque t	Comparación en el bloque t
Sin olvido	Todo el historial disponible	Referencia de permanencia.
Ventana corta	Últimas 4 semanas etiquetadas	Reacción rápida; mayor varianza.
Ventana media	Últimas 8 semanas etiquetadas	Compromiso entre recencia y muestra.
Ventana larga	Últimas 12 semanas etiquetadas	Más estabilidad; posible lentitud.

Cada iteración entrena con etiquetas disponibles antes de t , calibra en una subventana pasada, evalúa en el bloque futuro y agrega PR-AUC, recall, Brier, costo y métricas por UID. Un modelo nuevo sólo se promueve si mejora o iguala V01 en holdout temporal reciente, no empeora UID desconocido y respeta la capacidad operativa.

7 Limitaciones y cierre

Los costos son normalizados, no monetarios reales; el dataset está anonimizado; la equidad demográfica no puede auditarse directamente; y la política V05 excede levemente el cupo de revisión. Aun así, el proyecto cubre el ciclo de vida solicitado: definición del problema, EDA temporal, modelado, decisión, despliegue y adaptación, con evidencia reproducible en Kaggle para EDA y V01–V07. La recomendación final es V01 + V05 + monitoreo/calibración V06; V07 queda como benchmark complementario.

Referencias

- Bifet, A., & Gavalda, R. (2007). Learning from time-changing data with adaptive windowing. *Proceedings of the SIAM International Conference on Data Mining*.
- Gama, J., Zliobaite, I., Bifet, A., Pechenizkiy, M., & Bouchachia, A. (2014). A survey on concept drift adaptation. *ACM Computing Surveys*, 46(4), Article 44. <https://doi.org/10.1145/2523813>
- Google Cloud. (2026). *Deploying to Cloud Run using Cloud Build*. <https://docs.cloud.google.com/build/docs/deploying-builds/deploy-cloud-run>
- Niculescu-Mizil, A., & Caruana, R. (2005). Predicting good probabilities with supervised learning. *Proceedings of the 22nd International Conference on Machine Learning*, 625–632. <https://doi.org/10.1145/1102351.1102430>

- Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*, 10(3), e0118432. <https://doi.org/10.1371/journal.pone.0118432>
- Zadrozny, B., & Elkan, C. (2002). Transforming classifier scores into accurate multiclass probability estimates. *Proceedings of the Eighth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 694–699. <https://doi.org/10.1145/775047.775151>