

Sistema adaptativo de detección de fraude

IEEE-CIS Fraud Detection · Proyecto 1

Equipo: _____

UTEC · Planificación y Toma de Decisiones en IA

2026-1

Defensa diseñada para 15–20 minutos: problema, EDA, modelos, decisión, despliegue y adaptación.

Ruta de la presentación

Tiempo	Contenido	Evidencia
2 min	Problema, objetivos y restricciones	Consigna y rúbrica
3 min	EDA y preparación temporal	Notebook 1, salidas de Kaggle
4 min	Modelos y estrategias de adaptación	27 configuraciones, 141 ajustes
3 min	Monitoreo: dónde falla el detector	PSI vs. PR-AUC semanal
4 min	Decisión, costo y el hallazgo central	Política sobre 88 581 holdout
2 min	Arquitectura, riesgos y cierre	Protocolo de ciclo de vida

Tesis de la exposición

Construimos un sistema adaptativo, medimos que **sí** mejora la detección, y descubrimos que **no** mejora el costo. Vamos a explicar por qué eso es el resultado, no el fracaso.

Problema y alcance

- ▶ El caso de uso es fraude financiero en transacciones electrónicas.
- ▶ Cada transacción futura debe recibir una acción: aprobar, revisar o escalar.
- ▶ La etiqueta positiva es minoritaria: 3.50% de fraude en entrenamiento.

Alcance responsable

El sistema automatiza casos de bajo riesgo. Los casos ambiguos o de alto riesgo mantienen revisión humana y trazabilidad de la decisión.

La consigna pide un sistema inteligente adaptativo. Por eso la solución cubre predicción, decisión, acción, monitoreo y actualización.

Objetivos, restricciones y métricas

Decisión de diseño	Por qué importa	Métrica usada
Priorizar fraude minoritario	Accuracy puede ser engañosa con 3.50% de positivos	PR-AUC y recall
Separar pasado y futuro	Un split aleatorio sobreestima el rendimiento operativo	Validación temporal
Limitar revisión humana	El equipo operativo no puede revisar todo	Tasa de revisión y costo
Controlar incertidumbre	Un score alto no equivale a probabilidad calibrada	Brier y calibración
Adaptarse al cambio	Los patrones de fraude cambian por ventana	KS, PSI y métricas semanales

Criterio

PR-AUC es la métrica principal porque evalúa directamente el ranking de la clase minoritaria. ROC-AUC se reporta como complemento.

Hallazgos del equipo

590 540 transacciones etiquetadas, 506 691 sin etiqueta, tasa global de fraude de 3.499% y tasa semanal entre 1.85% y 5.06%.

- ▶ 74 variables superan 80% de faltantes.
- ▶ Train y test se separan con adversarial ROC-AUC 1.000.

Lectura

La evidencia muestra cambio temporal observable. No prueba sola que cambie $P(Y | X)$, pero sí obliga a validar con orden cronológico y monitorear ventanas futuras.

EDA de referencia y ajustes incorporados

Aporte revisado	Riesgo si se ignora	Decisión tomada
Faltantes de identidad	Tratar ausencia como ruido aleatorio	Mantener señal de identidad y reportar segmento UID
Faltantes por bloques V	Eliminar variables útiles por missingness alto	Auditar por grupos y no podar de forma automática
Monto con cola pesada	Borrar transacciones raras que pueden ser fraude	No eliminar outliers de monto
Montos con más de dos decimales	Perder una señal transaccional sencilla	Evaluated como indicador candidato
MLP como comparación	Asumir que boosting basta sin contrastar	Contrastar con familias lineal y de árbol único

El notebook externo se usó como insumo metodológico, no como fuente de métricas finales, porque usa otro split y otra política de costos.

Preparación temporal



TransactionDT creciente

- ▶ El preprocesamiento se ajusta con pasado y se aplica a validación y holdout.
- ▶ TransactionDT, día y semana se excluyen como predictores para evitar posición temporal absoluta.
- ▶ Las agregaciones UID sólo se aceptan si usan eventos previos a la transacción.

Justificación

El sistema operaría sobre transacciones futuras. La evaluación debe imitar esa condición.

Tres familias distintas

- ▶ Tradicional lineal: regresión logística
- ▶ Tradicional de árbol único: árbol de decisión
- ▶ Avanzado: *gradient boosting* en LightGBM, XGBoost y CatBoost

Seis estrategias por familia

Estática · periódica 14/30/45 d · historial · por alerta

27 configuraciones · 141 ajustes · 4.16 M predicciones

Protocolo idéntico para todas

Bloques de 7 días.

Latencia de etiqueta de 7 días: antes de un bloque que empieza en t , sólo se entrena con datos anteriores a $t - 7$ d.

Cada ajuste registra

`train_last_dt < available_before`.

La adaptación mejora la discriminación

PR-AUC media	Estático	14 d	30 d	45 d	Historial	Alerta
LightGBM	0.550	0.565	0.592	0.597	0.571	0.574
XGBoost	0.499	0.535	0.555	0.557	0.527	0.537
CatBoost	0.471	0.483	0.507	0.517	0.491	0.499

Cinco bloques y una sola semilla: una diferencia de medias no basta. Como las estrategias comparten bloques, la prueba correcta es un t pareado.

	LightGBM	XGBoost	CatBoost
45 d vs. estático	+0.046, $p = \mathbf{0.024}$	+0.058, $p = \mathbf{0.006}$	+0.046, $p = \mathbf{0.007}$
Bloques favorables	5/5	5/5	5/5
45 d vs. 30 d	$p = 0.296$	$p = 0.736$	$p = 0.037$

Adaptar supera a no adaptar en las tres familias. **45 vs. 30 días cabe dentro del ruido**: sostenemos la ventana deslizante, no el ajuste fino de su tamaño.

La adaptación no rescata a los tradicionales

Evaluamos los dos enfoques tradicionales con el **mismo** protocolo por bloques, no con una cifra agregada.

PR-AUC holdout	Estático	Periódico 45 d	Desv. entre bloques
Árbol de decisión	0.385	0.376	0.06
Regresión logística	0.288	0.323	0.16–0.19
LightGBM (referencia)	0.550	0.597	0.07

El árbol empeora al adaptarse

0.385 $\rightarrow$ 0.376. Reentrenar con ventana corta le quita datos sin darle capacidad.

La logística es inestable

Por bloque: 0.369, 0.126, 0.107, 0.395, 0.445. No converge con 185 variables.

El argumento para el enfoque avanzado no es sólo que rinde más: es que **responde a la adaptación**, que es la variable de estudio.

Decisión, costo y el hallazgo central

Escenario central	Costo/txn	Fraudes aprobados	Revisiones	Escalaciones
Aprobar todo, sin modelo	23.379	3 083	0	0
V01 estático con política	8.818	946	4 892	3 768
LightGBM periódico 45 d	8.925	817	4 898	4 015

El mejor PR-AUC **no** es el mejor costo: el periódico evita 129 fraudes más, a cambio de 247 escalaciones legítimas adicionales a USD 10 cada una.

El resultado principal del trabajo

Eficacia del analista de 60 a 100 %: mueve el costo **1.824** USD/txn.

Costo de reentrenar de USD 0 a 500: mueve el costo **0.028** USD/txn.

Una diferencia de **65×**. El sistema está limitado por la **capacidad de revisión humana**, no por la calidad del clasificador.

Costos de esta tabla: supuestos ilustrativos. Referencias para nueva sensibilidad: Forrester TEI (2026), USD 0.65/revisión y USD 4 para seguimiento de algunas falsas alertas; LexisNexis (2025), multiplicador total 5.75 para servicios financieros de EE. UU. Aún no se aplican a esta tabla.

Sensibilidad con referencias externas: selección en validación

Escenario de costo ilustrativo	V01 estático	Periódico 45 d
Fórmula literal: USD 4/toda escalación; prevención perfecta	8.025	7.783
USD 4/escalación legítima; eficacia 80/95 %	9.942	9.722
USD 4/toda escalación; eficacia 60/95 %	11.147	10.937

Lectura

En las tres sensibilidades, los umbrales se optimizaron sólo con validación y ganó la ventana de 45 días. Los números son costo por transacción sin actualización.

Forrester TEI (2026): USD 0.65/revisión y USD 4 de seguimiento de algunas falsas alertas. LexisNexis (2025): multiplicador total 5.75 por USD 1 de pérdida directa. Puede haber solapamiento de costos. El holdout ya inspeccionado no sirve como nueva prueba final.

Incertidumbre: calibración y abstención

El score no es una probabilidad

Media en holdout 0.143 frente a prevalencia 0.035: sobreestima $4.11\times$.

Isotónica ajustada *sólo con validación*:

	Bruto	Calibrado
Brier	0.0479	0.0219
Media	0.143	0.0355


−54.2 % de Brier, sin tocar el modelo ni el ranking.

La banda de revisión es abstención

Acción	Cobertura	Fraude
Aprobar	90.2 %	1.18 %
Revisar	5.5 %	8.87 %
Escalar	4.3 %	45.20 %

El 90 % automático retiene 1.18 % de fraude residual; la franja escalada concentra 45 %. Por eso la autonomía plena se limita a la banda inferior.

Arquitectura del sistema



Nivel de autonomía

Aprobación automática para bajo riesgo. Revisión humana para incertidumbre. Escalamiento con control y registro para alto riesgo.

Servicio desplegado y brechas operativas

Componente	Función	Evidencia o control
FastAPI	POST /predict, /health, /metrics	Score, probabilidad calibrada y acción
Docker	Empaquetar código y artefactos	Imagen reproducible del servicio
Artifact Registry	Almacenar imagen	Versión desplegable
Cloud Build	Construir y publicar imagen	cloudbuild.yaml versionado
Cloud Run	Servir contenedor HTTP	Servicio desplegado en us-central1
Pendiente	Cola diaria y etiquetas maduras	Cupo y rendimiento no cerrados por la API

La API está desplegada para demostración. Antes de operar faltan la cola de 158 revisiones/día, auditoría durable, autenticación, pruebas de carga e integración de etiquetas maduras.

Dónde falla el detector de drift

Semana	17	20	23	24	26
PSI del score	0.000	0.001	0.009	0.011	0.007
PR-AUC semanal	0.732	0.514	0.473	0.554	0.593

El PSI **nunca superó 0.011** mientras la PR-AUC caía un 35 %. El umbral convencional es 0.25: quedó 23× por encima de todo lo observado.

Qué significa

Es **concept drift sin covariate shift visible**: cambió $P(y | x)$ sin que la distribución del score lo delatara. Un detector no supervisado no puede ver eso por construcción.

Por eso la alerta es una **disyunción**: PSI sobre umbral o dos bloques ya etiquetados más de 10 % bajo la referencia. La segunda condición es la que protegió al sistema.

Dos auditorías de nuestro propio trabajo

1. La fuga de V01: medida, no supuesta

V01 calculó los cuartiles del monto sobre todas las filas, no sobre su ventana histórica. En vez de declararla y seguir, entrenamos el mismo modelo con y sin contaminación:

	Con fuga	Limpio
PR-AUC holdout	0.51656	0.51910

La versión contaminada rinde **0.0025 peor**. La fuga es real y se declara, pero **no otorga ventaja** y no sesga la comparación.

2. Features temporales: cumplidas y explicadas

Cinco variables de memoria por entidad con `shift(1)` dentro del UID. El modelo las usa —posiciones 19 a 43 de 190 por importancia— pero aportan $+0.0006$: las columnas `C*` y `D*` ya codifican recurrencia por entidad.

Limitaciones y riesgos

Límite	Cómo se controla
Costos normalizados	Repetir sensibilidad cuando existan costos reales
Dataset anonimizado	Evitar causalidad fuerte sobre variables sin significado de negocio
Cupo 158/día sólo en simulación	Añadir una cola con estado al servicio desplegado
Equidad demográfica no observable	Usar proxies operativos disponibles y reportar la limitación
Drift futuro desconocido	Monitoreo por ventanas y validación antes de promover modelos

Lo que no medimos

La eficacia real del analista, que es el parámetro que domina el costo. Los umbrales, la latencia de etiqueta de 7 días y los costos son supuestos declarados, no observaciones de operación.

Decisión final

Mantener V01 con política, conservar armada la infraestructura adaptativa —ventanas, detector, protocolo de promoción— y suspender el disparo automático de reentrenamiento hasta que un piloto mida la eficacia real del analista.

- ▶ Adaptar mejora la discriminación en las tres familias, con significancia estadística.
- ▶ Pero esa mejora no se convierte en ahorro: el cuello de botella es la capacidad de revisión, no el modelo.
- ▶ La calibración isotónica evita comunicar scores brutos como probabilidades.
- ▶ El aparato de medición que detecta esa reversión es el entregable; el modelo es secundario.


La recomendación de V01 se formuló tras observar la reversión en holdout; su ventaja económica como política seleccionada allí requiere otro periodo futuro de evaluación.

Infografía del ciclo completo

Sistema adaptativo para detección de fraude financiero

IEEE-CIS · Proyecto 1 · Evidencia alineada con la rúbrica de Planificación y Toma de Decisiones en IA

Ciclo de vida del sistema



El lazo 6→9 es lo que hace al sistema adaptativo: el modelo nunca se reemplaza sin validación en un bloque futuro.

Lo que medimos

Adaptar sí mejora la detección

PR-AUC media de holdout, ventana de 45 días frente a modelo congelado:

LightGBM 0.550 → 0.597 · XGBoost 0.499 → 0.557 · CatBoost 0.471 → 0.517

↑ pareado significativo en las tres ($p = 0.024, 0.006, 0.007$).

Pero no se traduce en ahorro

Costo ilustrativo por transacción en el escenario central:

Aprobar todo 23.379 · V01 con política 8.818 · periódico 45 d 8.925

Evita 129 fraudes más, a cambio de 247 escalaciones legítimas más a USD 10.

Dónde está la verdadera palanca

Eficacia del analista de 60 a 100 %: mueve el costo 1.824 USD/bn.

Costo de reentrenar de USD 0 a 500: mueve el costo 0.028 USD/bn.

65 × de diferencia. El límite es la revisión humana.

El detector sin etiquetas no vio la degradación

El PSI del score nunca superó 0.011 mientras la PR-AUC semanal caía de 0.732 a 0.473 (−35 %). El umbral convencional de 0.25 quedó 23 × por encima de todo lo observado.

Concept drift sin covariate shift: la alerta combina ambas señales.

Auditamos nuestro propio trabajo

Fuga de V01: medida, no supuesta. Con cuartiles contaminados PR-AUC 0.516/66; limpios 0.519/10. La versión con fuga rinde 0.0025 peor en esta auditoría aislada.

Calibración: el score sobreestima 4.11 ×. Isotónica baja Brier de 0.0479 a 0.0219.

Recomendación exploratoria: mantener V01 con política y conservar la infraestructura adaptativa. Se formuló tras ver la reventón en holdout; un período futuro debe probarla. Medir en piloto la eficacia real del analista antes de automatizar el reentrenamiento.

Atención: el costo central es ilustrativo; la sensibilidad con cifras de Forester y LevinLevy se seleccionó sólo en validación. La comparación uso etiquetas históricas, no es un ensayo causal. USD conocido/desconocido es un proxy operativo, no una prueba de equidad demográfica.