

Sistema temporal de decisión antifraude

IEEE-CIS Fraud Detection · Proyecto 1

Grupo NaN

UTEC · Planificación y Toma de Decisiones en IA

2026-1


¿Puede una política basada en riesgo reducir la pérdida simulada bajo un cupo diario de revisión?

Tres acciones

Aprobar riesgo bajo Revisar banda intermedia Escalar riesgo alto

El modelo ordena transacciones; la política convierte el score en acciones. Medimos PR-AUC, recall, F1, calibración, costo y demanda operativa. El cupo primario equivale al 5% de la mediana diaria del entrenamiento elegible: **159 revisiones por día**.

EDA temporal: cambian etiqueta, monto y calidad



La prevalencia pasó de 2.53% a cerca de 4%; la identidad ausente superó 81%. M7--M9 cambiaron 50.4 puntos de faltantes. El sexto periodo es parcial.

Protocolo temporal y controles de fuga

Etapa	Regla
Partición	70% entrenamiento, 15% validación, 15% holdout, en orden de TransactionDT
Ajuste interno	Dos folds dentro del entrenamiento, en 50–65% y 75–90% de su duración
Etiquetas	Sólo observaciones anteriores a $t - 7$ días para un bloque que empieza en t
Preprocesamiento	Encoder, frecuencias, imputación, cuartiles y selección de columnas V ajustados en la ventana histórica
Memoria UID	Cinco variables hechas sólo con eventos anteriores

Regla de evaluación



Los hiperparámetros y umbrales se congelan en validación antes de evaluar el holdout histórico.

Cuatro modelos, hiperparámetros por pasado

Modelo	PR-AUC interna	Ajuste seleccionado
Regresión logística	0.374	$C = 0.1$
Árbol de decisión	0.387	profundidad 10; hoja mínima 100
LightGBM	0.560	63 hojas; mínimo 100
XGBoost	0.536	profundidad 6; peso mínimo 30

- ▶ Dos modelos tradicionales y dos avanzados.
- ▶ Grid compacto y fijado antes del holdout; 28 ajustes en dos folds.
- ▶ Elección de hiperparámetros por PR-AUC media, peor fold y complejidad.

El rendimiento cambia entre semanas y ventanas



LightGBM 60 días logró la mayor PR-AUC de validación (0.586). XGBoost 30 días ganó cuando se evaluaron score, umbrales y costo conjuntamente. La variante disparada sin gate quedó como comparador técnico.

Función de costo: cifras y supuestos

$$C = 0.65 N_{\text{revisión}} + 4 N_{\text{escalación directa}} + 4 E[N_{\text{derivación}}] + 5.75 E[\text{monto de fraude no detenido}]$$

- ▶ **0.65 USD/revisión:** 0.75 minutos a 52 USD/h en el TEI de Forrester encargado por Mastercard.
- ▶ **4 USD/escalación:** supuesto de nuestro flujo. Forrester lo estima para seguimiento de algunas falsas alertas, no para esta derivación.
- ▶ **5.75 por monto:** costo total medio por dólar de pérdida directa en servicios financieros de EE. UU., LexisNexis 2025.

<https://tei.forrester.com/go/mastercard/decisionintelligenceandrullesservices/>
<https://risk.lexisnexis.com/insights-resources/research/US-CA-true-cost-of-fraud-study>

Elección por menor arrepentimiento

Se optimizaron umbrales dentro de validación para cada candidato. La regla minimiza el peor porcentaje de arrepentimiento frente al menor costo de cada escenario.

Eficacia revisión/escalación	Costo/txn elegido	Pérdida evitada
100/100	8.106	1.202 millones
90/98	9.189	1.152 millones
80/95	10.499	1.091 millones
60/90	12.776	0.986 millones

Elección congelada



XGBoost periódico, ventana 30 días; umbrales 0.3872 y 0.6521; cupo 159 revisiones/día.
Peor arrepentimiento 0% dentro del grid validado.

Holdout retrospectivo: predicción

Métrica	Resultado
Transacciones / fraudes	88 581 / 3 083
PR-AUC	0.548
Recall / F1 al umbral de escalación	0.597 / 0.485
Brier bruto / calibrado	0.06863 / 0.02195


La isotónica se ajustó sólo con la primera semana de validación. No cambia ranking ni umbrales. El modelo periódico usa sólo etiquetas con siete días de antigüedad. Las elecciones se congelaron antes de consultar las etiquetas de este periodo.

Cuatro escenarios; una política congelada



En 80/95: **12.312 por transacción** y **1.610 millones** de pérdida simulada evitada frente a aprobar todo. El cupo 3/5/10% modifica costo en validación; exige recursos humanos reales.

La escalación necesita capacidad propia



En 80/95 hubo 4 929 revisiones iniciales, 4 505 escalaciones directas y 280 derivaciones esperadas. La cola de escalación llegó a **376.8 casos esperados en un día**; su capacidad aún no está validada.


Resultados mensuales y cobertura UID

Periodo	Filas	PR-AUC	F1	Costo/txn 80/95
Mes 6	83 088	0.542	0.480	12.077
Mes 7, parcial	5 493	0.612	0.543	15.870

Cobertura UID	Filas	PR-AUC
No visto antes	49 069	0.570
Conocido	39 512	0.487


El último mes está incompleto. UID es un proxy de cobertura operativa, no una variable demográfica.

Calidad: una alerta y recuperación



La cota **0.4897** usa validación interna. Dos incumplimientos maduros activan candidato de 60 días y gate pasado separado. Aquí hubo una alerta y recuperación: **mantener**, sin promoción.

Arquitectura operativa propuesta



El código reproduce esta lógica de decisión y promoción sobre datos históricos. Un piloto debe probar latencia, disponibilidad de variables anonimizadas, eficacia humana y capacidad de la cola de escalación.

Límites y conclusión

- ▶ La mejora simulada depende de eficacias 100/100 a 60/90, no observadas en IEEE-CIS.
- ▶ La divisa de `TransactionAmt` es desconocida; el multiplicador 5.75 puede solaparse con costos operativos.
- ▶ La evaluación es histórica; una prueba con nuevas transacciones mediría desempeño prospectivo.
- ▶ En esta corrida, la regla de calidad mantuvo el modelo. No se puede atribuir una mejora a un reentrenamiento que no ocurrió.

Entrega reproducible

Cuatro notebooks y outputs IEEE-CIS en `08_entrega_final_codigo/`; el verificador comprobó cortes, cupo, elección congelada y conciliación de costos.