

Sistema adaptativo de detección de fraude

Datos no estacionarios · IEEE-CIS · Proyecto 1

Equipo: _____

UTEC · Planificación y Toma de Decisiones en IA

2026-1

1. El problema y la acción

- ▶ Fraude minoritario: 3.50% en train, según el EDA del equipo.
- ▶ Cambian patrones, clientes y prevalencia a lo largo del tiempo.
- ▶ Cada caso recibe un score y una acción: aprobar, revisar o escalar.

Tres objetivos

Detectar fraude, respetar la capacidad humana y reducir fricción de usuarios legítimos.

No suponemos que los datos futuros sigan exactamente la distribución del entrenamiento.

2. Evidencia temporal y preparación

Observaciones reportadas

590 540 transacciones etiquetadas; fraude semanal 1.85–5.06%; 74 atributos con $> 80\%$ de faltantes.

- ▶ Diferencias entre UID conocido y desconocido.
- ▶ Separación observable de train/test no demuestra por sí sola cambio en $P(Y | X)$.

Evaluación

70% entrenamiento $\rightarrow$ 15% validación $\rightarrow$ 15% prueba futura.

- ▶ Ajustar preprocesamiento sólo con pasado.
- ▶ Sin tiempo absoluto entre predictores.
- ▶ Agregaciones históricas disponibles antes de cada caso.

3. Modelos: qué medimos

Modelo	Papel	Estado
V01 LightGBM	Baseline temporal principal	Mejor holdout entre versiones: PR-AUC 0.5436.
V01b LightGBM full	Control con todas las features	No mejora holdout: PR-AUC 0.5303.
V02 UID features	Memoria histórica por entidad	Mejora UID conocido; empeora UID desconocido.
V04 XGBoost/CatBoost	Comparación avanzada	Ningún candidato supera V01.

Métrica principal

Área bajo precisión–recall para fraude minoritario; reportar también ROC-AUC, Brier y comportamiento por ventana.

Para cubrir literalmente dos modelos tradicionales, se recomienda añadir regresión logística y bosque aleatorio al notebook final con el mismo split temporal.

4. Resultados V01 reportados

Bloque	Fraude	PR-AUC	ROC-AUC
Validación	3.43%	0.5954	0.9257
Prueba futura	3.48%	0.5436	0.9051
Prueba UID conocido	1.93%	0.5159	0.9020
Prueba UID desconocido	4.73%	0.5632	0.8933

Lectura

Caída global de 0.0518 en PR-AUC. Es evidencia de degradación temporal y justifica monitoreo por ventanas y protocolo de adaptación.

5. La decisión importa tanto como el ranking

Política V05: score bruto

$s < 0.459783$: aprobar.

$0.459783 \leq s < 0.779122$: revisión.

$s \geq 0.779122$: escalar con control humano.


Costos simulados: fraude aprobado 100; legítima escalada 10; revisión 2.

Prueba reportada

Costo/txn **1.3680**; fraude enviado **66.17%**;
revisión **5.10%**; escalamiento **2.48%**.

La revisión supera el objetivo de 5%. Ajustar umbrales y cupos antes de operar.

6. Arquitectura y nivel de autonomía



- ▶ Aprobar bajo riesgo de forma automática; revisión humana en incertidumbre.
- ▶ Escalamiento con verificación adicional y ruta de apelación.
- ▶ Cambio de modelo sólo tras evaluación temporal y aprobación del equipo.

Calibración V06 reportada

Brier 0.0479 → 0.0219; verificar que el calibrador sólo vio datos anteriores al holdout.

7. Despliegue propuesto

Camino de producción

FastAPI → Docker → Cloud Build / Artifact Registry → Cloud Run.

Observabilidad

Logs minimizados → métricas de tráfico, latencia, proporción revisada y etiquetas tardías.

- ▶ Versionar modelo, preprocesamiento, calibrador y umbrales.
- ▶ Probar costos, latencia, acceso a datos y volumen antes de desplegar.

El servicio cloud es una propuesta de diseño basada en el taller GCP: API, Docker, Artifact Registry, Cloud Build y Cloud Run.

8. Detectar cambio y comparar olvido

Señal	Sin esperar etiquetas	Cuando llegan etiquetas
Entradas y score	KS, PSI, faltantes y percentiles	Distinguir si afectan errores.
Resultado y operación	Cupo de revisión y escalamiento	PR-AUC, recall, Brier, costo y segmentos.

Experimento pendiente

En cada bloque semanal futuro, comparar entrenamiento histórico frente a ventanas móviles de **4, 8 y 12 semanas**; mismas fechas de evaluación, sólo etiquetas disponibles al entrenar.

9. Síntesis y tareas de cierre

1. V01 y V05: resultados previos reportados; corroborarlos con notebooks y particiones.
2. Ejecutar dos enfoques tradicionales y boosting con los CSV originales.
3. Cuantificar PR-AUC y costo por ventana, incluido el experimento de olvido.
4. Aplicar un cupo $\leq 5\%$ y medir fricción sobre compras legítimas.

Mensaje final

Predicción, decisión y adaptación forman un mismo ciclo; cada actualización necesita validación temporal y trazabilidad.

Infografía del ciclo completo

Fraude financiero: un sistema que aprende, decide y se adapta

IEEE-CIS · Proyecto 1 · Planificación y Toma de Decisiones en IA

01 DATOS

Transacción + identidad unidas por TransactionID.

590540 casos etiquetados; **3.50%** fraude en train.

La fuente de competencia sin etiquetas no permite evaluar rendimiento.

02 EXPLORACIÓN

Tasa semanal reportada:
1.85–5.06%.

Faltantes, monto y diferencias entre UID conocido / desconocido.

Cambio en la distribución observable no prueba por sí solo concept drift.

03 PREPARACIÓN

Orden por tiempo: **70% / 15% / 15%**.

Imputación y codificación ajustadas en el pasado.

Variables históricas sólo con eventos previos a cada transacción.

04 MODELO

V01 LightGBM, cifras del equipo:
PR-AUC 0.5436 y ROC-AUC 0.9051 en prueba temporal.

V01 supera V01b y candidatos V04 en holdout.

08 ADAPTACIÓN

Recalibrar, ajustar umbrales o reentrenar.

Comparar olvido en **4 / 8 / 12 semanas** sobre los mismos bloques futuros.

Protocolo propuesto; falta medir su efecto.

07 VIGILANCIA

Distribución: KS / PSI y faltantes.

Con etiquetas tardías: PR-AUC, Brier, costo y cobertura por segmento.

Ventanas móviles de 7 y 30 días frente a referencia.

06 SERVICIO

Propuesta: API + imagen versionada + Cloud Run.

Guardar score, acción, latencia y versión con acceso controlado.

El despliegue aún requiere pruebas de carga y de integración.

05 ACCIÓN

V05: aprobar / revisión humana / escalar.

66.17% del fraude enviado a revisión o escalamiento; revisión **5.10%**.

Antes de operar, cumplir cupo de 5% exacto.

Decisión responsable: el score bruto decide con la política V05; una probabilidad calibrada requiere ajuste sólo con datos sesionados. Una alerta de cambio solicita validación temporal antes de promover una nueva versión.

Fuente: conigex UTEC, taller de despliegue GCP y artefactos V01-V06 del repositorio. Los resultados de ventanas deslizantes quedan como protocolo de adaptación propuesta.