

Sistema adaptativo de detección de fraude

IEEE-CIS Fraud Detection · Proyecto 1

Equipo: _____

UTEC · Planificación y Toma de Decisiones en IA

2026-1

Defensa diseñada para 15–20 minutos: problema, EDA, modelos, decisión, despliegue y adaptación.

Ruta de la presentación

Tiempo	Contenido	Evidencia
2 min	Problema, objetivos y restricciones	Consigna y rúbrica
4 min	EDA y decisiones de preparación	EDA propio y referencia externa
5 min	Modelado V01–V07 y selección	Métricas de Kaggle
4 min	Política, incertidumbre y despliegue	V05, V06 y taller GCP
3 min	Drift, adaptación, límites y cierre	Protocolo de ciclo de vida

Idea guía

La entrega defiende un sistema de decisión adaptativo. El modelo predice riesgo, la política decide una acción y el monitoreo define cuándo ajustar el sistema.

Problema y alcance

- ▶ El caso de uso es fraude financiero en transacciones electrónicas.
- ▶ Cada transacción futura debe recibir una acción: aprobar, revisar o escalar.
- ▶ La etiqueta positiva es minoritaria: 3.50% de fraude en entrenamiento.

Alcance responsable

El sistema automatiza casos de bajo riesgo. Los casos ambiguos o de alto riesgo mantienen revisión humana y trazabilidad de la decisión.

La consigna pide un sistema inteligente adaptativo. Por eso la solución cubre predicción, decisión, acción, monitoreo y actualización.

Objetivos, restricciones y métricas

Decisión de diseño	Por qué importa	Métrica usada
Priorizar fraude minoritario	Accuracy puede ser engañosa con 3.50% de positivos	PR-AUC y recall
Separar pasado y futuro	Un split aleatorio sobreestima el rendimiento operativo	Validación temporal
Limitar revisión humana	El equipo operativo no puede revisar todo	Tasa de revisión y costo
Controlar incertidumbre	Un score alto no equivale a probabilidad calibrada	Brier y calibración
Adaptarse al cambio	Los patrones de fraude cambian por ventana	KS, PSI y métricas semanales

Criterio

PR-AUC es la métrica principal porque evalúa directamente el ranking de la clase minoritaria. ROC-AUC se reporta como complemento.

Hallazgos del equipo

590 540 transacciones etiquetadas, 506 691 sin etiqueta, tasa global de fraude de 3.499% y tasa semanal entre 1.85% y 5.06%.

- ▶ 74 variables superan 80% de faltantes.
- ▶ Train y test se separan con adversarial ROC-AUC 1.000.

Lectura

La evidencia muestra cambio temporal observable. No prueba sola que cambie $P(Y | X)$, pero sí obliga a validar con orden cronológico y monitorear ventanas futuras.

EDA de referencia y ajustes incorporados

Aporte revisado	Riesgo si se ignora	Decisión tomada
Faltantes de identidad	Tratar ausencia como ruido aleatorio	Mantener señal de identidad y reportar segmento UID
Faltantes por bloques V	Eliminar variables útiles por missingness alto	Auditar por grupos y no podar de forma automática
Monto con cola pesada	Borrar transacciones raras que pueden ser fraude	No eliminar outliers de monto
Montos con más de dos decimales	Perder una señal transaccional sencilla	Agregar indicador multi-decimal en V07
MLP como comparación	Asumir que boosting basta sin contrastar	Ejecutar V07 con MLP ponderado

El notebook externo se usó como insumo metodológico, no como fuente de métricas finales, porque usa otro split y otra política de costos.

Preparación temporal



TransactionDT creciente

- ▶ El preprocesamiento se ajusta con pasado y se aplica a validación y holdout.
- ▶ TransactionDT, día y semana se excluyen como predictores para evitar posición temporal absoluta.
- ▶ Las agregaciones UID sólo se aceptan si usan eventos previos a la transacción.

Justificación

El sistema operaría sobre transacciones futuras. La evaluación debe imitar esa condición.

Diseño experimental V01–V07

Versión	Pregunta que responde	Decisión
V01	¿Qué tan fuerte es un LightGBM temporal con features auditables?	Modelo base
V01b	¿Conviene usar todas las features sin filtro?	No, empeora holdout
V02	¿La memoria de UID ayuda?	Ayuda sólo en UID conocido
V03	¿Qué variables conservar o vigilar?	Usar como auditoría
V04	¿Otro boosting supera al baseline?	No supera V01
V05	¿Cómo convertir score en acción?	Política inicial
V06	¿Qué tan calibrado y robusto es el score?	Calibrar si se comunica probabilidad
V07	¿Un MLP o baseline lineal mejora?	No reemplaza LightGBM

Resultados del modelo base

Bloque	Fraude	PR-AUC	ROC-AUC
Validación global	3.43%	0.5954	0.9257
Holdout global	3.48%	0.5436	0.9051
Holdout UID conocido	1.93%	0.5159	0.9020
Holdout UID desconocido	4.73%	0.5632	0.8933

Lectura

La caída de PR-AUC entre validación y holdout confirma que el rendimiento se degrada con el tiempo. Aun así, V01 conserva el mejor balance entre desempeño y generalización.

Comparaciones que no reemplazaron V01

Experimento	Resultado	Motivo de descarte
V01b con todas las features	Holdout PR-AUC 0.5303	Más variables no implicaron mejor generalización temporal
V02 con UID histórico	Global 0.5442, UID unknown 0.5315	Riesgo para clientes no vistos
V04 con features auditadas	Mejor candidato 0.5131	Podar agresivamente eliminó señal útil
V07 MLP ponderado	Holdout PR-AUC 0.2218	No aprovecha tan bien faltantes e interacciones tabulares
V07 SGD logística	Holdout PR-AUC 0.1638	Baseline lineal insuficiente para la estructura del problema

La decisión no se basó en popularidad de modelos, sino en evidencia temporal comparable.

Reglas

$s < 0.459783$: aprobar.

$0.459783 \leq s < 0.779122$: revisión.

$s \geq 0.779122$: escalar.

- ▶ Fraude aprobado: costo 100.
- ▶ Legítima escalada: costo 10.
- ▶ Revisión manual: costo 2.

Holdout

Costo por transacción 1.3680.

Fraude detectado 66.17%.

Revisión 5.10%.

Escalamiento 2.48%.

La tasa de revisión supera levemente 5%, así que producción requiere cupo estricto por percentil o cola operativa.

Problema

El score bruto rankea transacciones, pero no debe presentarse como probabilidad directa.


- ▶ Score bruto medio en holdout: 14.30%.
- ▶ Tasa real de fraude: 3.48%.

Solución evaluada

Calibración isotónica entrenada con pasado.
Brier: 0.0479 a 0.0219.
Media calibrada: 3.55%.

Uso recomendado: score bruto para ranking,
score calibrado para comunicar probabilidad.

Arquitectura del sistema



Nivel de autonomía

Aprobación automática para bajo riesgo. Revisión humana para incertidumbre. Escalamiento con control y registro para alto riesgo.

Despliegue propuesto en GCP

Componente	Función	Evidencia o control
FastAPI	Exponer POST /predict	Entrada, score, decisión y versión
Docker	Empaquetar código y dependencias	Misma imagen para prueba y producción
Artifact Registry	Versionar imágenes	Trazabilidad de releases
Cloud Build	Construir desde GitHub	Automatizar pipeline de despliegue
Cloud Run	Servir contenedor HTTP	Escalado administrado y logs integrados
Monitoring	Vigilar latencia, errores y drift	Alertas operativas y técnicas

El despliegue queda como diseño técnico basado en el taller GCP. Antes de operar faltan pruebas de carga, integración y seguridad.

Drift y adaptación

Señal	Sin etiquetas	Con etiquetas tardías
Features	KS, PSI, missingness, percentiles	Relación con errores reales
Scores	Distribución del score y tasas sobre umbral	PR-AUC, Brier y recall
Operación	Revisión, escalamiento y latencia	Costo y fraude capturado
Segmentos	UID conocido y desconocido	Brechas de desempeño por segmento

Adaptación propuesta

Comparar entrenamiento histórico frente a ventanas móviles de 4, 8 y 12 semanas. Promover una versión sólo si mejora en bloque futuro y no empeora UID desconocido.

Criterio del curso	Evidencia en la entrega
Problema, objetivos y métricas	Caso fraude, restricciones, PR-AUC, costo, revisión y calibración
Análisis y preparación	EDA temporal, faltantes, UID, split 70/15/15 y control de leakage
Modelado y evaluación	V01–V07, comparación temporal, segmentación y holdout futuro
Sistema adaptativo	Arquitectura, acción, incertidumbre, drift y reentrenamiento
Producto entregado	Código Kaggle, GitHub, informes, diagramas, PDFs e infografía
Presentación	Guion de 15–20 minutos con defensa de decisiones

Limitaciones y riesgos

Límite	Cómo se controla
Costos normalizados	Repetir sensibilidad cuando existan costos reales
Dataset anonimizado	Evitar causalidad fuerte sobre variables sin significado de negocio
Revisión 5.10%	Aplicar cupo operativo estricto antes de producción
Equidad demográfica no observable	Usar proxies operativos disponibles y reportar la limitación
Drift futuro desconocido	Monitoreo por ventanas y validación antes de promover modelos

Riesgo académico restante

Si la lectura de la rúbrica exige dos modelos tradicionales estrictos, conviene agregar un Random Forest o HistGradientBoosting simple. No cambiaría la recomendación, pero cerraría el requisito formal.

Decisión final

Mantener V01 como modelo base, usar V05 como política inicial y usar V06 como soporte de calibración y robustez. V07 queda como benchmark adicional.

- ▶ V01 generaliza mejor en holdout temporal que las alternativas probadas.
- ▶ V05 convierte el ranking en decisiones con costo y capacidad explícitos.
- ▶ V06 evita comunicar scores brutos como probabilidades.
- ▶ El monitoreo convierte el clasificador en un sistema adaptativo.

La defensa central es conservadora: se elige la alternativa más estable y trazable, no la más compleja.

Infografía del ciclo completo

Sistema adaptativo para detección de fraude financiero

IEEE-CIS · Proyecto 1 · Evidencia alineada con la rúbrica de Planificación y Toma de Decisiones en IA

Cómo se cubre la rúbrica

01 Problema, objetivos y métricas

Caso: aprobar, revisar o escalar transacciones futuras.

Fraude en train: **3.50%**.

Métricas: PR-AUC, ROC-AUC, Brier, costo, revisión y fraude detectado.

02 Análisis y preparación

EDA temporal: **590 540** train, **506 691** test.

Fraude semanal: **1.85–5.06%**.

Split por tiempo **70/15/15**; sin leakage temporal.

03 Modelado y evaluación

V01–V07 ejecutados en Kaggle.

Modelo elegido: V01 LightGBM.

Holdout: **PR-AUC 0.5436**, ROC-AUC 0.9051.

04 Sistema adaptativo

Score, acción y monitoreo en un mismo ciclo.

V05 decide: aprobar / revisar / escalar.

V06 calibra incertidumbre y evalúa robustez.

05 Producto entregado

Repositorio GitHub, kernels públicos y outputs descargados.

Informe técnico, presentación, diagramas e infografía.

Despliegue propuesto: FastAPI, Docker, Cloud Build y Cloud Run.


06 Presentación y defensa

Deck preparado para **15–20 minutos**.

Cada decisión incluye evidencia y criterio.

Riesgo pendiente: agregar otro tradicional si se exige literalmente.

Ciclo operativo propuesto



Decisión final: usar V01 como modelo base, V05 como política inicial y V06 como soporte de calibración y robustez. V07 documenta que el MLP y el baseline lineal no reemplazan a LightGBM bajo el mismo split temporal.

Fuente: consorcio UTEC, taller de despliegue CCP, EDA del equipo, notebook público de referencia y artefactos V05–V07 del repositorio. La adaptación por ventanas móviles queda como protocolo propuesto para operaciones futuras.