

Sistema adaptativo de detección de fraude

Decisiones bajo datos no estacionarios en IEEE-CIS

Departamento de Ciencia de la Computación · Proyecto 1 · 2026-1

Equipo: _____ Fecha: _____

Resumen. Se diseña y evalúa un sistema inteligente adaptativo para detección de fraude financiero con datos temporales. El sistema integra transacciones e identidad, estima un score con un modelo LightGBM, traduce el score en acciones operativas y propone monitoreo de drift, calibración y reentrenamiento con ventanas deslizantes. Los resultados provienen de artefactos V01–V07 publicados como kernels de Kaggle y descargados al repositorio. La recomendación final es usar V01 como modelo base, V05 como política inicial y V06 como soporte de robustez/calibración. La defensa se organiza según la rúbrica del curso: problema, datos, modelado, sistema adaptativo, producto entregable y presentación.

1 Problema, objetivos y restricciones


El conjunto IEEE-CIS Fraud Detection contiene transacciones electrónicas y atributos de identidad unidos por `TransactionID`. El caso de uso es clasificar transacciones futuras como riesgo bajo, riesgo intermedio o riesgo alto, para decidir si se aprueban, se envían a revisión humana o se escalan. El problema es no estacionario: la tasa de fraude y la distribución de variables cambian en el tiempo. En la literatura, este fenómeno se asocia a *concept drift*, es decir, cambios temporales en la relación entre entradas y salida (Gama et al., 2014).

Objetivo	Métrica	Restricción o riesgo
Detectar fraude	PR-AUC, ROC-AUC, recall por ventana	Clase positiva minoritaria; no usar accuracy como criterio central.
Decidir con capacidad limitada	Costo normalizado, fraude capturado, revisión, escalamiento	Capacidad objetivo de revisión cercana a 5%.
Controlar incertidumbre	Brier, calibración, estabilidad del score	No comunicar score bruto como probabilidad sin calibración.
Monitorear drift	KS, PSI, missingness, métricas por ventana	No asumir que el entrenamiento representa indefinidamente al futuro.
Reducir fricción social	Legítimas escaladas, UID conocido/desconocido	Evitar automatizar casos ambiguos sin revisión humana.

La métrica principal de modelado es PR-AUC porque el fraude representa sólo 3.50% del entrenamiento; en datos desbalanceados, las curvas Precision-Recall son más informativas que ROC o accuracy para evaluar la clase minoritaria (Saito & Rehmsmeier, 2015). ROC-AUC se reporta como complemento.

2 Análisis y preparación temporal

El EDA propio reporta 590 540 transacciones etiquetadas, 506 691 registros de competencia sin etiqueta, 3.499% de fraude en entrenamiento, 74 variables con más de 80% de faltantes y tasa semanal de fraude entre 1.85% y 5.06%. Además, la validación adversarial train/test alcanzó ROC-AUC 1.000, señal de cambio observable entre periodos. Esto exige validación cronológica y evita tratar el problema como i.i.d.



Las transacciones se ordenan por `TransactionDT`. Los primeros 70% se usan para entrenamiento, el 15% siguiente para validación y el 15% final como holdout futuro. `TransactionDT`, `DT_day_index` y `DT_week_index` no se usan como predictores porque codifican posición temporal absoluta; se reservan para partición y monitoreo. Las agregaciones por UID se consideran válidas sólo si usan información disponible antes de la transacción evaluada.

El EDA externo revisado de Fabryzzio complementó la lectura del equipo en cuatro puntos: ausencia estructural de atributos de identidad, faltantes por bloques en variables `V`, montos con cola pesada y montos con más de dos decimales. La decisión no fue copiar su pipeline, porque usa otra partición y otra política de costos, sino contrastar sus observaciones con nuestro diseño temporal. Por eso `V07` incorpora `TransactionAmt_multi_decimal`, mantiene la evaluación por UID conocido/desconocido y agrega un MLP como benchmark bajo el mismo split 70/15/15 del proyecto.

3 Modelado y evaluación temporal

Se comparan tres familias distintas sobre la misma superficie de 185 variables: dos enfoques tradicionales —regresión logística y árbol de decisión— y un enfoque avanzado de *gradient boosting*, instanciado en LightGBM, XGBoost y CatBoost para verificar que los hallazgos no dependan de una implementación. La elección se justifica por la naturaleza tabular del dataset: variables numéricas y categóricas, faltantes masivos e interacciones no lineales, donde los árboles manejan nulos de forma nativa. Cada familia se evalúa con estrategia estática, reentrenamiento periódico con ventanas de 14, 30 y 45 días o historial acumulado, y reentrenamiento disparado por alerta: 27 configuraciones, 141 ajustes y 4 158 810 filas de predicción.

El protocolo es idéntico para todas: bloques consecutivos de siete días y una latencia de etiqueta de siete días, de modo que antes de un bloque que empieza en t solo se entrena con transacciones anteriores a $t - 7$ días. Cada ajuste registra `train_last_dt < available_before`, verificable en el registro de ajustes.

Modelo	Estático	Per. 14 d	Per. 30 d	Per. 45 d	Per. hist.	Alerta 45 d
LightGBM	0.550	0.565	0.592	0.597	0.571	0.574
XGBoost	0.499	0.535	0.555	0.557	0.527	0.537
CatBoost	0.471	0.483	0.507	0.517	0.491	0.499

Cuadro 1: PR-AUC media de los cinco bloques de holdout.

Con cinco bloques y una sola semilla, una diferencia de medias no basta para afirmar un ranking. Como las estrategias comparten los mismos bloques, la prueba adecuada es un t pareado, que elimina la varianza entre bloques —la dominante, con desviaciones de 0.05 a 0.07 dentro de cada configuración.

Comparación	LightGBM	XGBoost	CatBoost
Periódico 45 d vs. estático	+0.046, $p = \mathbf{0.024}$	+0.058, $p = \mathbf{0.006}$	+0.046, $p = \mathbf{0.007}$
Bloques favorables	5/5	5/5	5/5
IC 95 % de la diferencia	[+0.010, +0.082]	[+0.028, +0.088]	[+0.021, +0.071]
Periódico 45 d vs. 30 d	+0.005, $p = 0.296$	+0.002, $p = 0.736$	+0.010, $p = 0.037$

Cuadro 2: Significancia del ranking de estrategias.

El experimento sustenta dos afirmaciones de alcance distinto. Adaptar supera a no adaptar en las tres familias, con intervalos que excluyen el cero y las cinco diferencias por bloque positivas. Dentro del rango óptimo, en cambio, 45 días no es distinguible de 30 en LightGBM ni XGBoost: esa diferencia cabe dentro

del ruido, de modo que se adopta 45 d por su media sin atribuirle superioridad estadística sobre 30. Lo demostrado es el valor de la ventana deslizante frente al modelo congelado, no el ajuste fino de su tamaño. Al cupo operativo del 5 %, LightGBM pasa de F1 0.488 estático a 0.521 con periódico de 45 d; XGBoost de 0.444 a 0.504 y CatBoost de 0.438 a 0.478. Las referencias tradicionales quedan muy por debajo en holdout —regresión logística 0.170 y árbol de decisión 0.381 de PR-AUC—, con la salvedad de que usan imputación mediana y codificación numérica heredada, mientras los árboles tratan nulos de forma nativa: parte de la brecha es tratamiento de datos, no capacidad del modelo. Esas dos referencias se evaluaron además con el mismo protocolo por bloques, para que la comparación fuera homóloga: el árbol pasa de 0.385 estático a 0.376 con ventana de 45 d —es decir, *empeora* al adaptarse— y la regresión logística sube de 0.288 a 0.323 pero con desviación entre bloques de 0.16 a 0.19, oscilando entre 0.107 y 0.445 según el bloque. La adaptación no rescata a los modelos tradicionales. El contraste con los boosters, que mejoran con ventana deslizante en las tres familias y con significancia estadística, es el argumento real para preferir el enfoque avanzado: no sólo rinde más, sino que **responde a la adaptación**, que es la variable de estudio de este trabajo.

Dos controles de validez. El indicador de monto atípico de V01 se construyó con cuartiles calculados sobre todas las filas en lugar de su ventana histórica. El efecto está cuantificado: entrenando el mismo modelo con y sin esa contaminación, la PR-AUC de holdout resulta 0.51656 con fuga y 0.51910 sin ella, es decir, la versión contaminada rinde 0.0025 *peor*. La fuga es real y se declara, pero no otorga ventaja y no sesga la comparación. El segundo control atiende los atributos con dimensión temporal que pide el enunciado: cinco variables de memoria por entidad, construidas con `shift(1)` dentro del UID. El modelo las usa —posiciones 19 a 43 de 190 por importancia— pero aportan +0.0006 de PR-AUC, dentro del ruido: las columnas anonimizadas C* y D* ya codifican recurrencia por entidad.

4 Arquitectura, incertidumbre y decisión




Figura 1: Arquitectura funcional propuesta para predicción, decisión y adaptación.

El score no debe interpretarse como probabilidad: en holdout su promedio es 0.143 mientras la prevalencia observada es 0.035, una sobreestimación de $4.11\times$. Una isotónica ajustada *solo con validación* y aplicada a holdout corrige el nivel sin tocar el modelo ni el ranking: Brier baja de 0.04788 a 0.02192 (-54.2%) y la media calibrada queda en 0.0355, a $1.02\times$ de la prevalencia. Ajustarla con holdout habría filtrado el periodo reservado hacia la calibración, que es el error que el protocolo temporal evita en todo lo demás. Esto es coherente con la literatura: modelos fuertes pueden rankear bien y producir probabilidades sesgadas (Niculescu-Mizil & Caruana, 2005; Zadrozny & Elkan, 2002).

La política traduce el score en tres acciones, con umbrales elegidos en validación y congelados para holdout. El cupo diario es 158 revisiones, el 5 % de la mediana diaria de volumen del train inicial, y se aplica por día. El holdout evaluado tiene 88 581 transacciones con 3 083 fraudes.

Acción	Transacciones	Cobertura	Tasa de fraude
Aprobar (automático)	79 921	90.2 %	1.18 %
Revisar (analista)	4 892	5.5 %	8.87 %
Escalar (confirmación)	3 768	4.3 %	45.20 %

Cuadro 3: La banda de revisión funciona como región de abstención.

El 90.2 % decidido de forma automática retiene 1.18 % de fraude residual, mientras la franja escalada concentra 45.20 %. Eso justifica limitar la autonomía plena a la banda inferior: escalar es retención temporal con confirmación humana, nunca bloqueo irreversible autónomo.

Los costos son supuestos ilustrativos, no cifras de una empresa real: un fraude aprobado cuesta $4.41 \times$ el monto, una revisión USD 2, una legítima escalada USD 10 y cada reentrenamiento USD 100.

Escenario central	Costo/txn	Fraudes aprobados	Revisiones	Escalaciones
Aprobar todo, sin modelo	23.379	3 083	0	0
V01 estático con política	8.818	946	4 892	3 768
LightGBM periódico, historial	8.856	869	4 898	4 025
LightGBM periódico, 45 d	8.925	817	4 898	4 015

Bajo estos supuestos la política reduce el costo simulado 62.3 % frente a aprobar todo. Pero el resultado central del trabajo es otro: mover la eficacia del analista de 60 a 100 % desplaza el costo 1.824 USD/txn, mientras mover el cargo por reentrenar de USD 0 a 500 lo desplaza 0.028, una diferencia de $65 \times$. **El sistema está limitado por la capacidad de revisión humana, no por la calidad del clasificador:** ganar 0.046 de PR-AUC no se convierte en ahorro porque, con cupo fijo, un modelo que ordena mejor no puede revisar más y empuja masa hacia el escalamiento. Los umbrales se congelan en validación y se aplican a holdout sin retocar, porque reoptimizar sobre el periodo reservado sería sobreajuste de selección. Bajo esa disciplina, la configuración seleccionada en validación por costo —periódico de 45 d, 7.690 frente a 7.858 de V01— no sostiene su ventaja en holdout.

Como indicadores sociales observables, el desglose por UID registra 11.5 escalaciones falsas por cada 1 000 legítimas con UID conocido y 37.9 con UID desconocido, con cobertura de fraude referido de 64.0 % y 72.3 %. Esa brecha de $3.3 \times$ exige investigar captura de identidad antes de operar; UID conocido/desconocido no es un grupo demográfico protegido ni prueba equidad.

5 Riesgos de un sistema que se adapta solo

Un sistema que se reentrena por su cuenta introduce riesgos que un modelo congelado no tiene, y conviene nombrarlos.

Confianza. Los scores de distintos ajustes no comparten escala de calibración: un PSI alto puede reflejar que el modelo cambió, no que cambió la población. Interpretar esa señal como drift dispararía reentrenamientos en cadena, cada uno justificando el siguiente. Por eso la recalibración de umbrales se separa del reentrenamiento del modelo y usa solo bloques con etiquetas ya maduras.

Estabilidad. El detector sin etiquetas falló en el caso que importaba: el PSI del score nunca superó 0.011 mientras la PR-AUC semanal caía de 0.732 a 0.473. Es concept drift sin covariate shift visible, justamente lo que un detector no supervisado no puede ver por construcción. La regla de alerta es por eso una disyunción: PSI sobre umbral o dos bloques ya etiquetados más de 10 % bajo la referencia. La segunda condición es la que protege al sistema; la primera, sobre esta señal, nunca se activó.

Decisión automatizada. El 90.2 % de las transacciones se aprueba sin intervención, y ahí vive 1.18 % de fraude residual que nadie revisa. La cola de escalamiento, además, no está dimensionada: 3 768 escalaciones en unos 31 días implican unas 120 diarias de confirmación que se suman al cupo de revisión y que este trabajo no presupuesta. Antes de operar habría que fijar su límite.

Fricción desigual. El proxy por UID muestra $3.3\times$ más escalaciones falsas sobre entidades desconocidas. No es un grupo protegido, pero si la captura de identidad correlaciona con canal o dispositivo, el sistema trasladaría fricción de forma sistemática a una población. Se reporta como riesgo a investigar, no como métrica de equidad aprobada.

6 Despliegue y ciclo de vida

La propuesta de despliegue sigue el taller de GCP: API, contenedor, Artifact Registry, Cloud Build y Cloud Run. La API `POST /predict` recibe una transacción, genera features, calcula score, aplica la política y retorna score, probabilidad calibrada opcional, decisión y versiones. Cloud Run es adecuado porque sirve contenedores HTTP, escala según demanda y se integra con Cloud Logging/Monitoring. Según la documentación oficial, Cloud Build puede construir la imagen, almacenarla en Artifact Registry y desplegarla en Cloud Run de forma automatizada.

Elemento	Cadencia propuesta	Regla de cambio
Operación y cupo	Diario	Vigilar revisión, escalamiento, legítimas afectadas y latencia.
Desempeño con etiquetas	Semanal	PR-AUC, recall, Brier y costo por bloque y segmento.
Umbrales y calibración	Semanal / mensual	Ajustar sólo con datos anteriores a la ventana evaluada.
Modelo	Mensual o alerta sostenida	Comparar candidato frente al vigente en bloque futuro intocado.

7 Drift y adaptación

La detección de drift combina señales inmediatas y señales con etiquetas tardías. Para numéricas se propone KS; para variables agrupadas o categóricas, PSI y cambios de missingness; para scores, percentiles y tasa sobre umbrales; para desempeño, PR-AUC, Brier, recall y costo por ventana. Las estrategias de olvido por ventanas deslizantes se apoyan en la idea de que datos antiguos pueden volverse menos relevantes cuando cambia el proceso generador (Bifet & Gavalda, 2007).

Escenario por simular	Entrenamiento antes del bloque t	Comparación en el bloque t
Sin olvido	Todo el historial disponible	Referencia de permanencia.
Ventana corta	Últimas 4 semanas etiquetadas	Reacción rápida; mayor varianza.
Ventana media	Últimas 8 semanas etiquetadas	Compromiso entre recencia y muestra.
Ventana larga	Últimas 12 semanas etiquetadas	Más estabilidad; posible lentitud.

Cada iteración entrena con etiquetas disponibles antes de t , calibra en una subventana pasada, evalúa en el bloque futuro y agrega PR-AUC, recall, Brier, costo y métricas por UID. Un modelo nuevo sólo se promueve si mejora o iguala V01 en holdout temporal reciente, no empeora UID desconocido y respeta la capacidad operativa.

8 Limitaciones y cierre

Los costos son normalizados, no monetarios reales; el dataset está anonimizado; la equidad demográfica no puede auditarse directamente; y la política V05 excede levemente el cupo de revisión. Aun así, el proyecto cubre el ciclo de vida solicitado: definición del problema, EDA temporal, modelado, decisión, despliegue y adaptación, con evidencia reproducible en Kaggle para EDA y V01–V07. La recomendación final es V01 + V05 + monitoreo/calibración V06; V07 queda como benchmark complementario.

Referencias

- Bifet, A., & Gavalda, R. (2007). Learning from time-changing data with adaptive windowing. *Proceedings of the SIAM International Conference on Data Mining*.
- Gama, J., Zliobaite, I., Bifet, A., Pechenizkiy, M., & Bouchachia, A. (2014). A survey on concept drift adaptation. *ACM Computing Surveys*, 46(4), Article 44. <https://doi.org/10.1145/2523813>
- Google Cloud. (2026). *Deploying to Cloud Run using Cloud Build*. <https://docs.cloud.google.com/build/docs/deploying-builds/deploy-cloud-run>
- Niculescu-Mizil, A., & Caruana, R. (2005). Predicting good probabilities with supervised learning. *Proceedings of the 22nd International Conference on Machine Learning*, 625–632. <https://doi.org/10.1145/1102351.1102430>
- Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*, 10(3), e0118432. <https://doi.org/10.1371/journal.pone.0118432>
- Zadrozny, B., & Elkan, C. (2002). Transforming classifier scores into accurate multiclass probability estimates. *Proceedings of the Eighth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 694–699. <https://doi.org/10.1145/775047.775151>